

TEMA 5

Mostreig i estimació

Com passar d'una mostra a una estimació útil de la població, entenent precisió, representativitat i biaix.

Què aprendrem?

Població i mostra	Distingir què volem conèixer i què observem realment.
Mostreig	Entendre com seleccionar persones i per què una mostra pot estar esbiaixada.
Estimació	Utilitzar dades de la mostra per aproximar característiques de la població.
Error mostral	Entendre per què dues mostres donen resultats diferents.
Qualitat	Valorar representativitat, precisió i possibles biaixos.

El mostreig és el pont entre les dades que tenim i la població sobre la qual volem concloure.

1. Població, mostra i unitat estadística

Població	Conjunt complet sobre el qual volem obtenir informació: tots els treballadors d'una empresa, sector o territori.
Mostra	Subconjunt de la població que observem.
Unitat estadística	Element individual que mesurem: persona, empresa, contracte, accident...
Cens	Estudi de tota la població; evita error mostral però pot ser car i lent.

Exemple: què és població i què és mostra?

Exemple resolt pas a pas

Volem estimar la satisfacció dels 4.800 treballadors d'un grup empresarial i entrevistem 400 persones.

- Població = 4.800 treballadors.
- Mostra = 400 entrevistats.
- Variable = puntuació de satisfacció.

Interpretació: La mitjana dels 400 és un estadístic mostral; la mitjana real dels 4.800 és un paràmetre poblacional.

2. Per què fem mostres?

- Mesurar tota la població pot ser massa costós, lent o impossible.
- Una mostra ben dissenyada pot donar una estimació molt útil amb molts menys recursos.
- La mida de la mostra importa, però la manera de seleccionar-la és igualment important.
- Una mostra enorme però esbiaixada pot ser pitjor que una mostra més petita i aleatòria.

“Més dades” no compensa automàticament un mal disseny de mostreig.

3. Mostreig probabilístic



Aleatori simple

Totes les unitats tenen una probabilitat coneguda i igual de ser seleccionades.

Sistemàtic

Es tria un punt inicial aleatori i després cada k-è element.

Estratificat

Es divideix la població en grups rellevants i es mostreja dins de cada grup.

Conglomerats

Es seleccionen grups sencers, com centres de treball, i després s'estudien les unitats que contenen.

Mostreig estratificat

Exemple resolt pas a pas

Una empresa té 70% personal d'oficina i 30% de producció. Volem una mostra proporcional de 200 persones.

- Oficina: $0,70 \times 200 = 140$ persones.
- Producció: $0,30 \times 200 = 60$ persones.
- Dins de cada estrat, seleccionem aleatòriament.

Interpretació: L'estratificació garanteix que els dos grups apareguin en proporció adequada i pot millorar la precisió.

4. Mostreig no probabilístic

- Conveniència** Participen les persones més fàcils d'accedir.
- Voluntaris** Respon qui decideix participar.
- Quotes** Es fixen quantitats per grup, però la selecció dins del grup no és aleatòria.
- Risc** No podem assegurar que la mostra representi la població; el biaix pot ser important.

És útil en estudis exploratoris, però cal prudència per generalitzar resultats.

5. Què vol dir “representativa”?

- Una mostra és representativa quan reflecteix adequadament les característiques rellevants de la població per a l'objectiu de l'estudi.
- No significa que hagi de copiar exactament cada percentatge de la població.
- La representativitat depèn del disseny, de la cobertura, de la no-resposta i de com es recullen les dades.
- Cal preguntar qui ha quedat fora i si aquesta exclusió està relacionada amb el que mesurem.

6. Biaixos habituals



Cobertura	Part de la població no pot ser seleccionada perquè no apareix al marc mostral.
No-resposta	Les persones que no responen poden ser sistemàticament diferents de les que sí.
Autoselecció	Participen especialment persones amb opinions fortes o més disponibilitat.
Mesura	La pregunta, l'entrevistador o l'instrument poden alterar la resposta.

Exemple de biaix de no-resposta

Exemple resolt pas a pas

S'envia una enquesta de clima laboral a 1.000 persones i només responen 180.

- La taxa de resposta és 18%.
- Si les persones molt insatisfetes responen més, la mitjana pot quedar artificialment baixa.
- Si responen menys perquè temen ser identificades, podria passar el contrari.

Interpretació: El problema no és només “pocs casos”, sinó que els no-responents poden diferir dels responents.

7. Paràmetre i estadístic

Paràmetre	Valor real de la població, normalment desconegut: μ , p , σ ...
Estadístic	Valor calculat amb la mostra: mitjana $\bar{x}$, proporció $\hat{p}$, desviació s...
Estimador	Regla de càlcul que fem servir per estimar un paràmetre.
Estimació	Valor concret obtingut en una mostra determinada.

8. Estimar una mitjana

$$\bar{x} = (x_1 + x_2 + \dots + x_n) / n$$

- $\bar{x}$ és la mitjana mostral.
- n és la mida de la mostra.
- $\bar{x}$ s'utilitza habitualment per estimar la mitjana poblacional μ .

Exemple: Salaris 1.800, 2.000, 2.100 i 2.500 € → $\bar{x}=2.100$ €.

9. Estimar una proporció

$$\hat{p} = \text{nombre de casos amb la característica} / n$$

- $\hat{p}$ és la proporció observada a la mostra.
- Serveix per estimar la proporció poblacional p .
- Com més gran i ben seleccionada sigui la mostra, habitualment més estable serà $\hat{p}$.

Exemple: 72 de 300 persones prefereixen teletreball $\rightarrow \hat{p}=0,24=24\%$.

10. Error mostral

- Si repetíssim el mateix mostreig, obtindríem mostres diferents i, per tant, estadístics lleugerament diferents.
- Aquesta variació natural s'anomena error mostral.
- No és una equivocació: existeix fins i tot amb un mostreig perfecte.
- Disminueix quan augmenta la mida de la mostra, però no elimina els biaixos sistemàtics.

11. Error estàndard de la mitjana

$$SE(\bar{x}) = s / \sqrt{n}$$

- s és la desviació estàndard mostral.
- n és la mida de la mostra.
- El SE mesura quant variaria aproximadament la mitjana mostral entre mostres repetides.
- En quadruplicar n, el SE es redueix aproximadament a la meitat.

Exemple: $s=400 \text{ €}$ i $n=100 \rightarrow SE=40 \text{ €}$.

12. Error estàndard d'una proporció

$$SE(\hat{p}) \approx \sqrt{[\hat{p}(1-\hat{p})/n]}$$

- És una aproximació habitual per a mostres aleatòries simples.
- La incertesa és més gran quan p és prop de 0,5 i menor prop de 0 o 1.
- Augmentar n redueix el SE.

Exemple: $\hat{p}=0,40$ i $n=400 \rightarrow SE \approx 0,0245$, és a dir, 2,45 punts percentuals.

13. Distribució mostral

- Imaginem repetir l'estudi milers de vegades amb mostres de la mateixa mida.
- Cada mostra produiria una mitjana diferent. El conjunt d'aquestes mitjanes forma la distribució mostral de $\bar{x}$.
- El seu centre és aproximadament la mitjana poblacional i la seva dispersió és l'error estàndard.
- Aquesta idea és la base dels intervals de confiança i dels contrastos d'hipòtesis.

14. Llei dels grans nombres i teorema central

- La llei dels grans nombres explica que, amb mostres aleatòries cada vegada més grans, la mitjana mostral tendeix a estabilitzar-se prop de la mitjana poblacional.
- El teorema central del límit explica que la distribució de moltes mitjanes mostrals tendeix a ser aproximadament normal quan n és prou gran, sota condicions habituals.
- Això no significa que les dades originals hagin de ser normals.
- Són idees fonamentals per justificar molts mètodes d'inferència.

15. Mida de la mostra: què la determina?

- La precisió desitjada: més precisió requereix més mostra.
- La variabilitat de la població: més heterogeneïtat sol requerir més observacions.
- El nivell de confiança desitjat: més confiança implica intervals més amplis o mostres més grans.
- El disseny de mostreig, els recursos disponibles i la no-resposta esperada també importen.

No hi ha una mida “màgica” que sigui adequada per a tots els estudis.

Exemple complet d'estimació

Exemple resolt pas a pas

En una mostra aleatòria de 400 treballadors, 156 declaren que voldrien reduir la jornada encara que disminuís el salari.

- Estimació puntual: $\hat{p}=156/400=0,39=39\%$.
- $SE \approx \sqrt{(0,39 \times 0,61/400)}=0,0244$.
- La incertesa mostral és d'uns 2,4 punts percentuals per cada error estàndard.

Interpretació: 39% és la millor estimació puntual amb aquesta mostra; no afirmem que la proporció poblacional sigui exactament 39%.

16. Error mostrat ≠ error total

- L'error estàndard només quantifica la variabilitat deguda al mostreig sota determinades hipòtesis.
- No detecta preguntes mal formulades, dades incorrectes, cobertura deficient, autoselecció o no-resposta diferencial.
- Una estimació pot tenir un SE petit i estar molt esbiaixada.
- Per valorar un estudi cal mirar tant la precisió estadística com la qualitat del procés de recollida.

Resum del tema 5

Què has de retenir abans de continuar



La mostra és el subconjunt observat; la població és el conjunt sobre el qual volem concloure.



El mostreig probabilístic permet quantificar millor la incertesa.



Els estadístics mostrals estimen paràmetres poblacionals desconeguts.



L'error estàndard descriu la variabilitat de l'estimador entre mostres.



Una mostra gran no arregla un biaix sistemàtic.

Tema 5 • Com escollim el tipus de mostra?

DECISIÓ PAS A PAS

PAS 1 • Defineix la població: de qui vols obtenir conclusions?

PAS 2 • Necessites representar subgrups concrets? Si sí, l'estratificat és especialment útil.

PAS 3 • Tens una llista completa de la població? Si sí, pots fer aleatori simple o sistemàtic.

PAS 4 • La població està agrupada geogràficament o per centres? El mostreig per conglomerats pot reduir costos.

PAS 5 • Si la selecció no és aleatòria, deixa clar que és no probabilística i que la generalització és més limitada.

IDEA CLAU • El tipus de mostra no es tria perquè “agradi més”: depèn de la població, l'objectiu i de com podem accedir a les unitats.

Tema 5 • Exercici complet 1: estimar una mitjana

EXEMPLE RESOLT DE PRINCIPI A FI

Una empresa vol estimar el temps mitjà de desplaçament a la feina. Selecciona aleatòriament $n=64$ treballadors. La mostra dona $\bar{X}=38$ minuts i $s=16$ minuts.

PAS 1 • Població: tots els treballadors de l'empresa. Paràmetre desconegut: μ = temps mitjà real.

PAS 2 • Estimació puntual: $\bar{X}=38$ min. La millor estimació disponible de μ és, per tant, 38 min.

PAS 3 • Error estàndard: $SE=s/\sqrt{n}=16/\sqrt{64}=16/8=2$ min.

PAS 4 • Interpretació del SE: si repetíssim mostres semblants, les seves mitjanes variarien aproximadament amb una desviació de 2 min.

RESULTAT • Estimació puntual = 38 min; $SE = 2$ min.

INTERPRETACIÓ • No afirmem que μ sigui exactament 38. Quantifiquem també la precisió de l'estimació.

Tema 5 • Exercici complet 2: estimar una proporció

EXEMPLE RESOLT DE PRINCIPI A FI

Volem estimar quina proporció de la plantilla prefereix teletreballar almenys 2 dies/setmana. En una mostra aleatòria de $n=500$, ho prefereixen 320 persones.

PAS 1 • Variable: sí/no. **Paràmetre:** p = proporció real de la plantilla.

PAS 2 • $\hat{p}=320/500=0,64=64\%$.

PAS 3 • $SE(\hat{p})\approx\sqrt{[0,64\times0,36/500]}=\sqrt{0,0004608}\approx0,0215$.

PAS 4 • En punts percentuals, $SE\approx2,15$ punts.

RESULTAT • Estimem que el 64% prefereix ≥ 2 dies de teletreball, amb $SE\approx2,15$ punts percentuals.

INTERPRETACIÓ • El 64% és l'estimació; el SE ens diu la precisió mostral. Al tema 7 el convertirem en un interval de confiança.

Tema 5 • Exercici complet 3: mostra estratificada

EXEMPLE RESOLT DE PRINCIPI A FI

Una organització té 2.400 treballadors: 1.200 administració, 720 producció i 480 comercial. Volem una mostra proporcional de $n=300$.

PAS 1 • Pes administració $=1.200/2.400=0,50 \rightarrow 0,50 \times 300=150$.

PAS 2 • Pes producció $=720/2.400=0,30 \rightarrow 0,30 \times 300=90$.

PAS 3 • Pes comercial $=480/2.400=0,20 \rightarrow 0,20 \times 300=60$.

PAS 4 • Dins de cada estrat, seleccionem les persones aleatòriament.

RESULTAT • Mostra: 150 administració + 90 producció + 60 comercial = 300.

INTERPRETACIÓ • Conservem el pes de cada grup i evitem que un departament petit o gran quedi accidentalment mal representat.

Tema 5 • Què has de saber fer

PROCEDIMENT GENERAL

- 1 • Identificar població, mostra i unitat estadística.
- 2 • Decidir si el disseny és probabilístic i quin tipus és adequat.
- 3 • Detectar possibles biaixos: cobertura, no-resposta, autoselecció.
- 4 • Identificar el paràmetre que volem estimar: μ o p , principalment.
- 5 • Calcular l'estimació puntual: $\bar{x}$ o $\hat{p}$.
- 6 • Calcular l'error estàndard quan sigui possible.
- 7 • Interpretar en paraules què representa l'estimació i quina precisió té.
- 8 • Recordar: una mostra gran no corregeix automàticament una mostra esbiaixada.